

# Econometria Aplicada

## Regressão linear múltipla

---

João Ricardo Costa Filho

*"The most important questions of life are, for the most part, really only problems in probability."*

Laplace (1812)

*"In God we trust. All others must bring data."*

William Edwards Deming

# Regressão múltipla

---

## Motivação (tudo começa com uma pergunta)

O que explica o comércio bilateral entre os países?

## A equação de 33 trilhões de dólares

O modelo gravitacional é muito conhecido nos cursos de Economia Internacional e já figura no Capítulo 2 de Krugman, Obstfeld, and Melitz (2023). Na sua forma mais simples, a equação que sintetiza as trocas comerciais bilaterais entre países pode ser escrita como:

$$T_{o,d} = \frac{Y_o \times Y_d}{D_{o,d}}$$

onde  $T_{i,j}$  representa o fluxo comercial bilateral entre o país de origem ( $o$ ) e o país de destino ( $d$ ),  $Y_o$  é o PIB do país de origem,  $Y_d$  é o PIB do país de destino e  $D_{o,d}$  a distância entre eles.

## A equação de 33 trilhões de dólares

O modelo gravitacional é muito conhecido nos cursos de Economia Internacional e já figura no Capítulo 2 de Krugman, Obstfeld, and Melitz (2023). Na sua forma mais simples, a equação que sintetiza as trocas comerciais bilaterais entre países pode ser escrita como:

$$T_{o,d} = \frac{Y_o \times Y_d}{D_{o,d}}$$

onde  $T_{i,j}$  representa o fluxo comercial bilateral entre o país de origem ( $o$ ) e o país de destino ( $d$ ),  $Y_o$  é o PIB do país de origem,  $Y_d$  é o PIB do país de destino e  $D_{o,d}$  a distância entre eles. Como podemos estimar essa relação não-linear com uma regressão linear?

## A equação de 33 trilhões de dólares

O primeiro passo, será escrevê-la de uma maneira um pouco mais genérica:

## A equação de 33 trilhões de dólares

O primeiro passo, será escrevê-la de uma maneira um pouco mais genérica:

$$T_{o,d} = \frac{Y_o^{\beta_1} \times Y_d^{\beta_2}}{D_{o,d}^{\beta_3}}$$



## Regressão múltipla

Agora, podemos estimar a equação do slide anterior:

Agora, podemos estimar a equação do slide anterior:

$$\ln T_{o,d} = \beta_1 Y_o + \beta_2 Y_d + \beta_3 \ln Dist_{i,j} + \varepsilon_{o,d}.$$

(Coloquei  $+\beta_3$  para expressar, genericamente, a regressão).

# Regressão múltipla

- Generalização da regressão simples na qual incluimos mais de uma variável explicativa.

# Regressão múltipla

- Generalização da regressão simples na qual incluimos mais de uma variável explicativa.
- Podemos ter (i) a variável explicada,

# Regressão múltipla

- Generalização da regressão simples na qual incluimos mais de uma variável explicativa.
- Podemos ter (i) a variável explicada, (ii) a(s) variável(is) de interesse

# Regressão múltipla

- Generalização da regressão simples na qual incluimos mais de uma variável explicativa.
- Podemos ter (i) a variável explicada, (ii) a(s) variável(is) de interesse e (iii) variáveis de controle.

# Regressão múltipla

- Generalização da regressão simples na qual incluimos mais de uma variável explicativa.
- Podemos ter (i) a variável explicada, (ii) a(s) variável(is) de interesse e (iii) variáveis de controle.
- A diferença é que agora temos diversas dimensões.

- Como responder a questão que motivou a nossa análise?



- Como responder a questão que motivou a nossa análise?
  - Utilizemos o capítulo 3 de Wooldridge (2006).

# Regressão múltipla

## Regressão múltipla

$$Y_i = \beta_0 + \beta_1 X_{1,i} + \beta_2 X_{2,i} + \cdots + \beta_k X_{k,i} + \varepsilon_i.$$

# Regressão múltipla

$$Y_i = \beta_0 + \beta_1 X_{1,i} + \beta_2 X_{2,i} + \cdots + \beta_k X_{k,i} + \varepsilon_i.$$

[Clique aqui para a matemática do estimador](#)

## $R^2$ e $R^2$ ajustado

## $R^2$ e $R^2$ ajustado

- Como podemos comparar modelos? A estatística  $R^2$  **não** é uma boa maneira.

## $R^2$ e $R^2$ ajustado

- Como podemos comparar modelos? A estatística  $R^2$  **não** é uma boa maneira.
- Podemos utilizar o  $R^2$  ajustado, no entanto:

$$R_{\text{adj}}^2 = 1 - (1 - R^2) \frac{n - 1}{n - k - 1} \quad (1)$$

onde  $n$  é o número de observações da amostra e  $k$  representa o número de variáveis independentes do modelo.

Podemos testar a significância conjunta dos estimadores:

$$\mathcal{H}_0 : \beta_0 = \beta_1 = \beta_2 = \cdots = \beta_k = 0$$

$$\mathcal{H}_a : \beta_j \neq 0, \text{ para menos um valor de } j$$

$$F = \frac{\sum_i \epsilon_i^2 - \sum_i e_i^2}{\sum_i e_i^2} \frac{n - k_2}{k_2 - k_1} \sim F_{k_2 - k_1, n - k_2} \quad (2)$$

onde  $k_2$  é o número de parâmetros do modelos irrestrito e  $k_1$  o número de parâmetros do modelo restrito.



Voltemos à questão dos fluxos comerciais.

## Regressão múltipla (modelo gravitacional)

<i>Variável dependente:</i>	
Log do Comércio	
Ln PIB (Origem)	0.944*** (0.006)
Ln PIB (Destino)	0.622*** (0.006)
Ln Distância	-2.344*** (0.015)
Observations	28,159
R <sup>2</sup>	0.907
Adjusted R <sup>2</sup>	0.907
<i>Nota:</i> * p<0.1; ** p<0.05; *** p<0.01	

# Regressão múltipla (modelo gravitacional)

	<i>Variável dependente:</i>
	Log do Comércio
Ln PIB (Origem)	0.901*** (0.006)
Ln PIB (Destino)	0.612*** (0.006)
Ln Distância	-2.373*** (0.015)
Membro da OMC (Origem)	0.971*** (0.049)
Membro da OMC (Destino)	0.420*** (0.050)
Observations	28,159
R <sup>2</sup>	0.909
Adjusted R <sup>2</sup>	0.909

*Nota:*

\* $p < 0.1$ ; \*\* $p < 0.05$ ; \*\*\* $p < 0.01$

A relação entre o PIB do país de origem e o fluxo de comércio bilateral é estatisticamente significativa?

A relação entre o PIB do país de origem e o fluxo de comércio bilateral é estatisticamente significativa?

Com a estatística  $\hat{\beta}_1$ , podemos realizar o seguinte teste:

A relação entre o PIB do país de origem e o fluxo de comércio bilateral é estatisticamente significativa?

Com a estatística  $\hat{\beta}_1$ , podemos realizar o seguinte teste:

$$\mathcal{H}_0 : \beta_1 = \mu$$

$$\mathcal{H}_a : \beta_1 \neq \mu$$

E a significância conjunta?

E a significância conjunta? Com a estatística  $F$ , podemos realizar o seguinte teste:



E a significância conjunta? Com a estatística  $F$ , podemos realizar o seguinte teste:

$$\mathcal{H}_0 : \beta_0 = \beta_1 = 0$$

$$\mathcal{H}_a : \beta_j \neq 0, \text{ para } j = [0, 1]$$

Vamos olhar para os resíduos.

## **Viés de variável omitida**

---

Quão eficiente é o mercado futuro de câmbio?

- Paridade descoberta da taxas de juros (log):  $i_t - E_t[d] = i_t^*$

Quão eficiente é o mercado futuro de câmbio?

- Paridade descoberta da taxas de juros (log):  $i_t - E_t[d] = i_t^*$
- Paridade coberta da taxas de juros:  $e_t(1 + i_t) \frac{1}{F_{t,t+1}} = (1 + i_t^*)$

## Eficiência no mercado de câmbio futuro

Quão eficiente é o mercado futuro de câmbio?

- Paridade descoberta da taxas de juros (log):  $i_t - E_t[d] = i_t^*$
- Paridade coberta da taxas de juros:  $e_t(1 + i_t) \frac{1}{F_{t,t+1}} = (1 + i_t^*)$ 
  - $\ln e_t + \ln(1 + i_t) + \ln 1 - \ln F_{t,t+1} = \ln(1 + i_t^*)$

## Eficiência no mercado de câmbio futuro

Quão eficiente é o mercado futuro de câmbio?

- Paridade descoberta da taxas de juros (log):  $i_t - E_t[d] = i_t^*$
- Paridade coberta da taxas de juros:  $e_t(1 + i_t) \frac{1}{F_{t,t+1}} = (1 + i_t^*)$ 
  - $\ln e_t + \ln(1 + i_t) + \ln 1 - \ln F_{t,t+1} = \ln(1 + i_t^*)$
  - $\ln e_t + i_t - \ln F_{t,t+1} = i_t^*$

## Eficiência no mercado de câmbio futuro

Quão eficiente é o mercado futuro de câmbio?

- Paridade descoberta da taxas de juros (log):  $i_t - E_t[d] = i_t^*$
- Paridade coberta da taxas de juros:  $e_t(1 + i_t) \frac{1}{F_{t,t+1}} = (1 + i_t^*)$ 
  - $\ln e_t + \ln(1 + i_t) + \ln 1 - \ln F_{t,t+1} = \ln(1 + i_t^*)$
  - $\ln e_t + i_t - \ln F_{t,t+1} = i_t^*$
  - $i_t = i_t^* + f_{t,t+1}$ , onde  $f_{t,t+1} = \ln F_{t,t+1} - \ln e_t$ .



## **Eficiência no mercado de câmbio futuro**

Os mercados serão eficientes:

## **Eficiência no mercado de câmbio futuro**

Os mercados serão eficientes: sem oportunidades de arbitragem

## Eficiência no mercado de câmbio futuro

Os mercados serão eficientes: sem oportunidades de arbitragem (retorno da paridade descoberta em  $i_t^*$  deve ser igual ao retorno da paridade coberta em também medido em  $i_t^*$ ):

## Eficiência no mercado de câmbio futuro

Os mercados serão eficientes: sem oportunidades de arbitragem (retorno da paridade descoberta em  $i_t^*$  deve ser igual ao retorno da paridade coberta em também medido em  $i_t^*$ ):

- $i_t - E_t[d_t] = i_t - f_{t,t+1}$
- $E_t[d_t] = f_{t,t+1}$

## Eficiência no mercado de câmbio futuro

Os mercados serão eficientes: sem oportunidades de arbitragem (retorno da paridade descoberta em  $i_t^*$  deve ser igual ao retorno da paridade coberta em também medido em  $i_t^*$ ):

- $i_t - E_t[d_t] = i_t - f_{t,t+1}$
- $E_t[d_t] = f_{t,t+1}$

Assumindo expectativas racionais:

## Eficiência no mercado de câmbio futuro

Os mercados serão eficientes: sem oportunidades de arbitragem (retorno da paridade descoberta em  $i_t^*$  deve ser igual ao retorno da paridade coberta em também medido em  $i_t^*$ ):

- $i_t - E_t[d_t] = i_t - f_{t,t+1}$
- $E_t[d_t] = f_{t,t+1}$

Assumindo expectativas racionais:

$$E_t[d_t] = d_t + \epsilon_{t+1}, \epsilon_{t+1} \sim D(0, \sigma^2).$$

## Eficiência no mercado de câmbio futuro

Os mercados serão eficientes: sem oportunidades de arbitragem (retorno da paridade descoberta em  $i_t^*$  deve ser igual ao retorno da paridade coberta em também medido em  $i_t^*$ ):

- $i_t - E_t[d_t] = i_t - f_{t,t+1}$
- $E_t[d_t] = f_{t,t+1}$

Assumindo expectativas racionais:

$E_t[d_t] = d_t + \epsilon_{t+1}, \epsilon_{t+1} \sim D(0, \sigma^2)$ . Portanto,

$$f_{t,t+1} = d_t + \epsilon_{t+1}, \epsilon_{t+1} \sim D(0, \sigma^2) \iff \\ d_t = f_{t,t+1} + u_{t+1}, u_{t+1} \sim D'(0, \sigma^2)$$

## Testando a eficiência do mercado de câmbio

Partindo da relação teórica,  $d_t = f_{t,t+1} + u_{t+1}$ , podemos testar eficiência do mercado de câmbio com base na seguinte regressão:



## Testando a eficiência do mercado de câmbio

Partindo da relação teórica,  $d_t = f_{t,t+1} + u_{t+1}$ , podemos testar eficiência do mercado de câmbio com base na seguinte regressão:

$$d_t = \beta_0 + \beta_1 f_{t,t+1} + u_{t+1}$$

## Testando a eficiência do mercado de câmbio

Partindo da relação teórica,  $d_t = f_{t,t+1} + u_{t+1}$ , podemos testar eficiência do mercado de câmbio com base na seguinte regressão:

$$d_t = \beta_0 + \beta_1 f_{t,t+1} + u_{t+1}$$

Se o mercado for eficiente, sabemos que:

$$\begin{aligned}\mathcal{H}_0 : \\ \beta_0 &= 0 \\ \beta_1 &= 1\end{aligned}$$

## Testando a eficiência do mercado de câmbio

Partindo da relação teórica,  $d_t = f_{t,t+1} + u_{t+1}$ , podemos testar eficiência do mercado de câmbio com base na seguinte regressão:

$$d_t = \beta_0 + \beta_1 f_{t,t+1} + u_{t+1}$$

Se o mercado for eficiente, sabemos que:

$$\beta_0 = 0$$

$$\mathcal{H}_0 :$$

$$\beta_1 = 1$$

Resultados encontrados:  $\beta_0 \neq 0$

## Testando a eficiência do mercado de câmbio

Partindo da relação teórica,  $d_t = f_{t,t+1} + u_{t+1}$ , podemos testar eficiência do mercado de câmbio com base na seguinte regressão:

$$d_t = \beta_0 + \beta_1 f_{t,t+1} + u_{t+1}$$

Se o mercado for eficiente, sabemos que:

$$\beta_0 = 0$$

$$\mathcal{H}_0 :$$

$$\beta_1 = 1$$

Resultados encontrados:  $\beta_0 \neq 0$  e  $\beta_1 < 0$ .

## Prêmio pelo risco cambial

Trabalhemos com a seguinte especificação:

## Prêmio pelo risco cambial

Trabalhemos com a seguinte especificação:

- $i_t - E_t[d_t] = i_t - f_{t,t+1} - RP_t$

## Prêmio pelo risco cambial

Trabalhemos com a seguinte especificação:

- $i_t - E_t[d_t] = i_t - f_{t,t+1} - RP_t$
- $E_t[d_t] = f_{t,t+1} + RP_t$

## Prêmio pelo risco cambial

Trabalhemos com a seguinte especificação:

- $i_t - E_t[d_t] = i_t - f_{t,t+1} - RP_t$
- $E_t[d_t] = f_{t,t+1} + RP_t$

Assumindo expectativas racionais, temos:



## Prêmio pelo risco cambial

Trabalhemos com a seguinte especificação:

- $i_t - E_t[d_t] = i_t - f_{t,t+1} - RP_t$
- $E_t[d_t] = f_{t,t+1} + RP_t$

Assumindo expectativas racionais, temos:

$$E_t[d_t] = d_t + \epsilon_{t+1}, \epsilon_{t+1} \sim D(0, \sigma^2)$$

## Prêmio pelo risco cambial

Trabalhemos com a seguinte especificação:

- $i_t - E_t[d_t] = i_t - f_{t,t+1} - RP_t$
- $E_t[d_t] = f_{t,t+1} + RP_t$

Assumindo expectativas racionais, temos:

$$E_t[d_t] = d_t + \epsilon_{t+1}, \epsilon_{t+1} \sim D(0, \sigma^2)$$

Portanto

$$\begin{aligned} f_{t,t+1} + RP_t &= d_t + \epsilon_{t+1}, \epsilon_{t+1} \sim D(0, \sigma^2) \iff \\ d_t &= f_{t,t+1} + RP_t + u_{t+1}, u_{t+1} \sim D'(0, \sigma^2). \end{aligned}$$

## Decomposição de Fama (1984)

Tomando como base o estimador de mínimos quadrados, sabemos que:

## Decomposição de Fama (1984)

Tomando como base o estimador de mínimos quadrados, sabemos que:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n d_i f_{i;t,t+1}}{\sum_{i=1}^n (f_{i;t,t+1})^2}$$

## Decomposição de Fama (1984)

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (f_{i;t,t+1} + RP_i + u_{i;t+1}) \cdot f_{i;t,t+1}}{\sum_{i=1}^n (f_{i;t,t+1})^2}$$

## Decomposição de Fama (1984)

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (f_{i;t,t+1} + RP_i + u_{i;t+1}) \cdot f_{i;t,t+1}}{\sum_{i=1}^n (f_{i;t,t+1})^2}$$

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (f_{i;t,t+1})^2}{\sum_{i=1}^n (f_{i;t,t+1})^2} + \frac{\sum_{i=1}^n RP_i \cdot f_{i;t,t+1}}{\sum_{i=1}^n (f_{i;t,t+1})^2} + \frac{\sum_{i=1}^n u_{i;t+1} \cdot f_{i;t,t+1}}{\sum_{i=1}^n (f_{i;t,t+1})^2}$$

## Decomposição de Fama (1984)

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (f_{i;t,t+1} + RP_i + u_{i;t+1}) \cdot f_{i;t,t+1}}{\sum_{i=1}^n (f_{i;t,t+1})^2}$$

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (f_{i;t,t+1})^2}{\sum_{i=1}^n (f_{i;t,t+1})^2} + \frac{\sum_{i=1}^n RP_i \cdot f_{i;t,t+1}}{\sum_{i=1}^n (f_{i;t,t+1})^2} + \frac{\sum_{i=1}^n u_{i;t+1} \cdot f_{i;t,t+1}}{\sum_{i=1}^n (f_{i;t,t+1})^2}$$

$$\hat{\beta}_1 = 1 + \frac{\sum_{i=1}^n RP_i \cdot f_{i;t,t+1}}{\sum_{i=1}^n (f_{i;t,t+1})^2} + 0$$

## Decomposição de Fama (1984)

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (f_{i;t,t+1} + RP_i + u_{i;t+1}) \cdot f_{i;t,t+1}}{\sum_{i=1}^n (f_{i;t,t+1})^2}$$

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (f_{i;t,t+1})^2}{\sum_{i=1}^n (f_{i;t,t+1})^2} + \frac{\sum_{i=1}^n RP_i \cdot f_{i;t,t+1}}{\sum_{i=1}^n (f_{i;t,t+1})^2} + \frac{\sum_{i=1}^n u_{i;t+1} \cdot f_{i;t,t+1}}{\sum_{i=1}^n (f_{i;t,t+1})^2}$$

$$\hat{\beta}_1 = 1 + \frac{\sum_{i=1}^n RP_i \cdot f_{i;t,t+1}}{\sum_{i=1}^n (f_{i;t,t+1})^2} + 0$$

$$plim \hat{\beta}_1 = 1 + \frac{COV[RP, f_{t,t+1}]}{VAR[f_{t,t+1}]}$$



## Decomposição de Fama (1984)

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (f_{i;t,t+1} + RP_i + u_{i;t+1}) \cdot f_{i;t,t+1}}{\sum_{i=1}^n (f_{i;t,t+1})^2}$$

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (f_{i;t,t+1})^2}{\sum_{i=1}^n (f_{i;t,t+1})^2} + \frac{\sum_{i=1}^n RP_i \cdot f_{i;t,t+1}}{\sum_{i=1}^n (f_{i;t,t+1})^2} + \frac{\sum_{i=1}^n u_{i;t+1} \cdot f_{i;t,t+1}}{\sum_{i=1}^n (f_{i;t,t+1})^2}$$

$$\hat{\beta}_1 = 1 + \frac{\sum_{i=1}^n RP_i \cdot f_{i;t,t+1}}{\sum_{i=1}^n (f_{i;t,t+1})^2} + 0$$

$$plim \hat{\beta}_1 = 1 + \frac{COV[RP, f_{t,t+1}]}{VAR[f_{t,t+1}]}$$

$$plim \hat{\beta}_1 = 1 + \frac{COV[RP, f_{t,t+1}]}{\sigma_{f_{t,t+1}} \cdot \sigma_{f_{t,t+1}}} \frac{\sigma_{RP}}{\sigma_{RP}}$$

## Decomposição de Fama (1984)

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (f_{i;t,t+1} + RP_i + u_{i;t+1}) \cdot f_{i;t,t+1}}{\sum_{i=1}^n (f_{i;t,t+1})^2}$$

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (f_{i;t,t+1})^2}{\sum_{i=1}^n (f_{i;t,t+1})^2} + \frac{\sum_{i=1}^n RP_i \cdot f_{i;t,t+1}}{\sum_{i=1}^n (f_{i;t,t+1})^2} + \frac{\sum_{i=1}^n u_{i;t+1} \cdot f_{i;t,t+1}}{\sum_{i=1}^n (f_{i;t,t+1})^2}$$

$$\hat{\beta}_1 = 1 + \frac{\sum_{i=1}^n RP_i \cdot f_{i;t,t+1}}{\sum_{i=1}^n (f_{i;t,t+1})^2} + 0$$

$$plim \hat{\beta}_1 = 1 + \frac{COV[RP, f_{t,t+1}]}{VAR[f_{t,t+1}]}$$

$$plim \hat{\beta}_1 = 1 + \frac{COV[RP, f_{t,t+1}]}{\sigma_{f_{t,t+1}} \cdot \sigma_{f_{t,t+1}}} \frac{\sigma_{RP}}{\sigma_{RP}}$$

$$plim \hat{\beta}_1 = 1 + \rho_{f_{t,t+1}, RP} \cdot \frac{\sigma_{RP}}{\sigma_{f_{t,t+1}}}$$

Se  $\hat{\beta}_1 < 0$ , então  $\rho_{f_{t,t+1}, RP} < 0$  e  $\sigma_{RP} > \sigma_{f_{t,t+1}}$ .

## Viés de variável omitida [Wooldridge (2006); p. 87-88]

Se

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + u_i,$$

e como

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_{i1} - \bar{x}_1) y_i}{\sum_{i=1}^n (x_{i1} - \bar{x}_1)^2},$$

Temos que

$$\sum_{i=1}^n (x_{i1} - \bar{x}_1) (\beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + u_i) = \beta_1 \sum_{i=1}^n (x_{i1} - \bar{x}_1)^2 + \beta_2 \sum_{i=1}^n (x_{i1} - \bar{x}_1) x_{i2} + \sum_{i=1}^n (x_{i1} - \bar{x}_1) u_i.$$

## Viés de variável omitida [Wooldridge (2006); p. 87-88]

Ao dividirmos o último resultado por  $\sum_{i=1}^n (x_{i1} - \bar{x}_1)^2$ , caso consideremos a esperança condicionada aos valores das variáveis independentes e usemos  $E(u_i) = 0$ , temos que:

$$E(\hat{\beta}_1) = \beta_1 + \beta_2 \frac{\sum_{i=1}^n (x_{i1} - \bar{x}_1) x_{i2}}{\sum_{i=1}^n (x_{i1} - \bar{x}_1)^2}.$$

Portanto,  $E(\hat{\beta}_1) \neq \beta_1$ .

## Viés de variável omitida [Wooldridge (2006); p. 87-88]

	$\text{Corr}(x_1, x_2) > 0$	$\text{Corr}(x_1, x_2) < 0$
$\beta_2 > 0$	viés positivo	viés negativo
$\beta_2 < 0$	viés negativo	viés positivo

# Apêndice

---

## Regressão múltipla – estimador de MQO

- $\min_{\hat{\beta}_0, \hat{\beta}_1, \hat{\beta}_2} \sum_{i=1}^n (\epsilon_i)^2 = \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_{1,i} - \hat{\beta}_2 X_{2,i})^2$

## Regressão múltipla – estimador de MQO

- $\min_{\hat{\beta}_0, \hat{\beta}_1, \hat{\beta}_2} \sum_{i=1}^n (\epsilon_i)^2 = \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_{1,i} - \hat{\beta}_2 X_{2,i})^2$ 
  - $\hat{\beta}_1 = \frac{\rho_{X_1, Y} - \rho_{X_1, X_2} \times \rho_{X_2, Y}}{1 - \rho_{X_1, X_2}^2}$
  - $\hat{\beta}_2 = \frac{\rho_{X_2, X_1} - \rho_{X_1, X_2} \times \rho_{X_1, Y}}{1 - \rho_{X_1, Y}^2}$
  - $\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}_1 - \hat{\beta}_2 \bar{X}_2$

◀ Retornar



## Regressão múltipla – estimador de MQO

E com mais variáveis?

## Regressão múltipla – estimador de MQO

E com mais variáveis? Vamos utilizar álgebra matricial! Podemos escrever o modelo da seguinte forma:

$$\begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ \vdots \\ Y_n \end{bmatrix}_{n \times 1} = \begin{bmatrix} 1 & X_{11} & X_{21} & \dots & X_{k1} \\ 1 & X_{12} & X_{22} & \dots & X_{k2} \\ \vdots & \vdots & \vdots & \dots & \vdots \\ \vdots & \vdots & \vdots & \dots & \vdots \\ 1 & X_{1n} & X_{2n} & \dots & X_{kn} \end{bmatrix}_{n \times k} \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \vdots \\ \beta_n \end{bmatrix}_{k \times 1} + \begin{bmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \vdots \\ \epsilon_n \end{bmatrix}_{n \times 1}$$

Ou, simplesmente

$$Y = X\beta + \epsilon.$$

## Regressão múltipla – estimador de MQO

O resíduo (não o erro) pode ser definido como

$$e = Y - X\beta \quad (3)$$

A soma dos quadrados dos resíduos pode ser escrita como:

$$\begin{bmatrix} e_1 & e_2 & \dots & e_n \end{bmatrix}_{1 \times n} \begin{bmatrix} e_1 \\ e_2 \\ \vdots \\ e_n \end{bmatrix}_{n \times 1} = [e_1 \times e_1 + e_2 \times e_2 + \dots + e_n \times e_n]_{1 \times 1}$$

## Regressão múltipla – estimador de MQO

$$\begin{aligned}e'e &= (\mathbf{Y} - \mathbf{X}\hat{\beta})'(\mathbf{Y} - \mathbf{X}\hat{\beta}) \\&= \mathbf{Y}'\mathbf{Y} - \hat{\beta}'\mathbf{X}'\mathbf{Y} - \mathbf{Y}'\mathbf{X}\hat{\beta} + \hat{\beta}'\mathbf{X}'\mathbf{X}\hat{\beta} \\&= \mathbf{Y}'\mathbf{Y} - 2\hat{\beta}'\mathbf{X}'\mathbf{Y} + \hat{\beta}'\mathbf{X}'\mathbf{X}\hat{\beta}\end{aligned}\tag{4}$$

Assim, temos

$$\frac{\partial e'e}{\partial \hat{\beta}} = -2\mathbf{X}'\mathbf{Y} + 2\mathbf{X}'\mathbf{X}\hat{\beta} = 0\tag{5}$$

é igual a

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}(\mathbf{X}'\mathbf{Y}).$$

- Fama, Eugene F. 1984. "Forward and Spot Exchange Rates."  
*Journal of Monetary Economics* 14 (3): 319–38.
- Krugman, Paul, Maurice Obstfeld, and Marc J Melitz. 2023.  
*Economia Internacional: Teoria e Política*. 12ª edição. Pearson.
- Wooldridge, Jeffrey M. 2006. *Introdução à Econometria: Uma Abordagem Moderna*. Cengage Learning.