Introdução à Estatística

Análise Bidimensional de Variáveis Qualitativas

João Ricardo Costa Filho

Leia os livros, não fique só com os slides!!!!

Qual é a associação entre recessões e inflação alta no Brasil?

Análise multivariada

Geralmente, estamos interessados em análises de mais de uma variável.

Geralmente, estamos interessados em análises de mais de uma variável. Se tivermos duas variáveis, quais são as opções?

Geralmente, estamos interessados em análises de mais de uma variável. Se tivermos duas variáveis, quais são as opções?

- Duas variáveis qualitativas.

Geralmente, estamos interessados em análises de mais de uma variável. Se tivermos duas variáveis, quais são as opções?

- Duas variáveis qualitativas.
- Duas variáveis quantitativas.

Geralmente, estamos interessados em análises de mais de uma variável. Se tivermos duas variáveis, quais são as opções?

- Duas variáveis qualitativas.
- Duas variáveis quantitativas.
- Uma variável qualitativa e uma variável quantitativa.

Geralmente, estamos interessados em análises de mais de uma variável. Se tivermos duas variáveis, quais são as opções?

- Duas variáveis qualitativas.
- Duas variáveis quantitativas.
- Uma variável qualitativa e uma variável quantitativa.

Diferentes tipos de variáveis implicam em técnicas estatísticas/econométricas diferentes!

Trabalhemos com a definição de duas variáveis:

Trabalhemos com a definição de duas variáveis:

- **Ciclo econômico**: por simplicidade, assuma que a economia pode estar em **recessão** ou **expansão** em um dado trimestre.

Trabalhemos com a definição de duas variáveis:

- **Ciclo econômico**: por simplicidade, assuma que a economia pode estar em **recessão** ou **expansão** em um dado trimestre.
- **Dinâmica de preços**: por simplicidade, assuma que a taxa de inflação trimestral anualizada por estar acima ou abaixo de 5% ao ano em um dado trimestre.

Trabalhemos com a definição de duas variáveis:

- **Ciclo econômico**: por simplicidade, assuma que a economia pode estar em **recessão** ou **expansão** em um dado trimestre.
- **Dinâmica de preços**: por simplicidade, assuma que a taxa de inflação trimestral anualizada por estar acima ou abaixo de 5% ao ano em um dado trimestre.

Qual é o tipo de cada variável?

O que é mais frequente no Brasil: recessão ou expansão?

O que é mais frequente no Brasil: inflação alta ($>5\%$ a.a.) ou baixa ($<5\%$ a.a.)?

Distribuição conjunta (Bussab and Morettin 2010)

- Uma distribuição conjunta fornece o total de observações de duas variáveis a partir da contagem de cada valor observação.
- Geralmmente, trabalhamos com **frequências relativas**:
  - Em relação ao total geral.

Distribuição conjunta (Bussab and Morettin 2010)

- Uma distribuição conjunta fornece o total de observações de duas variáveis a partir da contagem de cada valor observação.
- Geralmmente, trabalhamos com **frequências relativas**:
  - Em relação ao total geral.
  - Em relação ao total de cada coluna.

Distribuição conjunta (Bussab and Morettin 2010)

- Uma distribuição conjunta fornece o total de observações de duas variáveis a partir da contagem de cada valor observação.
- Geralmmente, trabalhamos com **frequências relativas**:
  - Em relação ao total geral.
  - Em relação ao total de cada coluna.
  - Em relação ao total de cada linha.

Ciclo econômico e a Dinâmica de preços

Vamos considerar os 120 trimestres ($n = 120$) entre 1996T1 e 2025T4.

Ciclo econômico e a Dinâmica de preços

Vamos considerar os 120 trimestres ($n = 120$) entre 1996T1 e 2025T4. Primeiro, com a **frequência absoluta**:

	Recessao	Expansao	Total
Acima de 5%	10	56	66
Abaixo de 5%	7	47	54
Total	17	103	120

Ciclo econômico e a Dinâmica de preços

Agora, com a frequência em relação ao total geral:

	Recessao	Expansao	Total
Acima de 5%	8.3%	46.7%	55.0%
Abaixo de 5%	5.8%	39.2%	45.0%
Total	14.2%	85.8%	100.0%

Ciclo econômico e a Dinâmica de preços

Por fim, com a frequência em relação ao total das colunas:

	Recessao	Expansao	Total
Acima de 5%	58.8%	54.4%	55.0%
Abaixo de 5%	41.2%	45.6%	45.0%
Total	100.0%	100.0%	100.0%

Exercício – Ciclo econômico e a Dinâmica de preços

Com base nos dados abaixo, construa a tabela com a frequência em relação ao total das linhas:

	Recessao	Expansao	Total
Acima de 5%	10	56	66
Abaixo de 5%	7	47	54
Total	17	103	120

E se usarmos dados a partir de 2007?

Ciclo econômico e a Dinâmica de preços, 2007 em diante (frequência absoluta)

Vamos considerar apenas os 76 trimestres entre 2007T1 e 2025T4.

	Recessao	Expansao	Total
Acima de 5%	8	29	37
Abaixo de 5%	7	32	39
Total	15	61	76

Ciclo econômico e a Dinâmica de preços, 2007 em diante (frequência em relação ao total geral)

	Recessao	Expansao	Total
Acima de 5%	10.5%	38.2%	48.7%
Abaixo de 5%	9.2%	42.1%	51.3%
Total	19.7%	80.3%	100.0%

Ciclo econômico e a Dinâmica de preços, 2007 em diante (frequência em relação ao total das colunas)

	Recessao	Expansao	Total
Acima de 5%	53.3%	47.5%	48.7%
Abaixo de 5%	46.7%	52.5%	51.3%
Total	100.0%	100.0%	100.0%

O que fazer?

Grau de associação entre variáveis qualitativas

Grau de associação entre variáveis qualitativas

O grau de associação entre variáveis qualitativas pode ser avaliado pela **distância entre os dados observados e o que aconteceria sob independência entre as variáveis**.

Grau de associação entre variáveis qualitativas

O grau de associação entre variáveis qualitativas pode ser avaliado pela **distância entre os dados observados e o que aconteceria sob independência entre as variáveis**.

Trabalhemos com a estatística qui-quadrado (χ^2). Ela serve de base, por exemplo, para calcularmos o **coeficiente de contingência de Pearson** e o **V de Cramér** (que fica entre 0 e 1; é ideal para tabelas maiores do que 2×2).

Exemplo: cooperativas e estado (Bussab and Morettin 2010)

Considere os tipos de cooperativas em operação e os estados em que elas funcionam:

	Consumidor	Produtor	Escola	Outras	Total
Sao Paulo	214 (33%)	237 (37%)	78 (12%)	119 (18%)	648 (100%)
Parana	51 (17%)	102 (34%)	126 (42%)	22 (7%)	301 (100%)
Rio G. do Sul	111 (18%)	304 (50%)	139 (23%)	48 (8%)	602 (100%)
Total	376 (24%)	643 (41%)	343 (22%)	189 (12%)	1.551 (100%)

Tabela esperada sob independência

Se aplicarmos os percentuais globais a cada estado, obtemos a tabela esperada:

	Consumidor	Produtor	Escola	Outras	Total
Sao Paulo	157 (24%)	269 (42%)	143 (22%)	79 (12%)	648 (100%)
Parana	73 (24%)	125 (41%)	67 (22%)	37 (12%)	301 (100%)
Rio G. do Sul	146 (24%)	250 (42%)	133 (22%)	73 (12%)	602 (100%)
Total	376 (24%)	643 (41%)	343 (22%)	189 (12%)	1.551 (100%)

Como calcular a tabela esperada?

Sob independência entre as variáveis, o valor esperado em cada célula é:

$$e_{ij} = \frac{(\text{total da linha } i)(\text{total da coluna } j)}{\text{total geral}}$$

Como calcular a tabela esperada?

Sob independência entre as variáveis, o valor esperado em cada célula é:

$$e_{ij} = \frac{(\text{total da linha } i)(\text{total da coluna } j)}{\text{total geral}}$$

Exemplo, para São Paulo e cooperativas do tipo Consumidor:

$$e_{\text{SP, Consumidor}} = \frac{648 \times 376}{1551} \approx 157$$

Como calcular a tabela esperada?

Sob independência entre as variáveis, o valor esperado em cada célula é:

$$e_{ij} = \frac{(\text{total da linha } i)(\text{total da coluna } j)}{\text{total geral}}$$

Exemplo, para São Paulo e cooperativas do tipo Consumidor:

$$e_{\text{SP, Consumidor}} = \frac{648 \times 376}{1551} \approx 157$$

Ou seja, se não houvesse associação entre estado e tipo de cooperativa, esperaríamos cerca de 157 cooperativas de consumo em São Paulo.

Resíduos: observado menos esperado

Agora comparamos o observado com o valor esperado em cada célula:

	Consumidor	Produtor	Escola	Outras	Total
Sao Paulo	57	-32	-65	40	0
Parana	-22	-23	59	-15	-1
Rio G. do Sul	-35	54	6	-25	0
Total	0	-1	0	0	0

Estatística qui-quadrado

Para cada célula, calculamos:

$$\chi^2 = \sum \frac{(o_i - e_i)^2}{e_i}$$

Estatística qui-quadrado

Para cada célula, calculamos:

$$\chi^2 = \sum \frac{(o_i - e_i)^2}{e_i}$$

No nosso exemplo:

$$\chi^2 = 173.38$$

Um valor alto de χ^2 indica que as variáveis estão mais associadas.

Medidas de associação

Com base no χ^2, podemos resumir o grau de associação por:

$$C = \sqrt{\frac{\chi^2}{\chi^2 + n}} \qquad V = \sqrt{\frac{\chi^2}{n \cdot \min(r-1, c-1)}}$$

Medidas de associação

Com base no χ^2, podemos resumir o grau de associação por:

$$C = \sqrt{\frac{\chi^2}{\chi^2 + n}} \qquad V = \sqrt{\frac{\chi^2}{n \cdot \min(r-1, c-1)}}$$

No exemplo:

- Coeficiente de contingência de Pearson: 0.317
- V de Cramér: 0.236

Exercício – Ciclo econômico e a Dinâmica de preços

Com base nos dados abaixo, calcule o Coeficiente de contingência de Pearson.

	Recessao	Expansao	Total
Acima de 5%	10	56	66
Abaixo de 5%	7	47	54
Total	17	103	120

Referências i

Bussab, Wilton de Oliveira, and Pedro Alberto Morettin. 2010. *Estatística Básica*. 6th ed. São Paulo: Saraiva.

Sicsú, Abraham Laredo. 2010. *Credit Scoring: Desenvolvimento, Implantação e Acompanhamento*. 1st ed. São Paulo: Editora Blucher.