

Introdução à Estatística

Análise Bidimensional de Variáveis Quantitativas

João Ricardo Costa Filho

Leia os **livros**, não fique só com os slides!!!!

Qual é a associação entre a taxa de câmbio e os riscos geopolíticos no Brasil?

Análise multivariada

Já vimos que se tivermos duas variáveis, podemos trabalhar com:

- Duas variáveis qualitativas.
- Duas variáveis quantitativas.
- Uma variável qualitativa e uma variável quantitativa.

Diferentes tipos de variáveis implicam em técnicas estatísticas/econométricas diferentes!

Análise multivariada

Trabalhemos com **duas variáveis quantitativas**, de tal forma que os dados observados podem ser divididos em pares:

Análise multivariada

Trabalhemos com **duas variáveis quantitativas**, de tal forma que os dados observados podem ser divididos em pares:

$$(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n).$$

Trabalhemos com **duas variáveis quantitativas**, de tal forma que os dados observados podem ser divididos em pares:

$$(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n).$$

O que se observa em dados bidimensionais?

- Como os valores de X variam junto aos valores de Y .

Trabalhemos com **duas variáveis quantitativas**, de tal forma que os dados observados podem ser divididos em pares:

$$(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n).$$

O que se observa em dados bidimensionais?

- Como os valores de X variam junto aos valores de Y .
- Se a relação entre eles parece linear ou não-linear.

Trabalhemos com **duas variáveis quantitativas**, de tal forma que os dados observados podem ser divididos em pares:

$$(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n).$$

O que se observa em dados bidimensionais?

- Como os valores de X variam junto aos valores de Y .
- Se a relação entre eles parece linear ou não-linear.

Pergunta-guia

Quando X aumenta, o que tende a acontecer com Y ?

Gráfico de dispersão

Gráfico de dispersão

O gráfico de dispersão representa cada par (x_i, y_i) por um ponto no plano cartesiano.

Gráfico de dispersão

O gráfico de dispersão representa cada par (x_i, y_i) por um ponto no plano cartesiano. Ele é, geralmente, o primeiro passo da análise explorativa de dados.

Gráfico de dispersão

O gráfico de dispersão representa cada par (x_i, y_i) por um ponto no plano cartesiano. Ele é, geralmente, o primeiro passo da análise explorativa de dados. Nele, podemos **começar** a explorar:

- **Sentido:** se há **associação** entre as variáveis (positiva ou negativa).

Gráfico de dispersão

O gráfico de dispersão representa cada par (x_i, y_i) por um ponto no plano cartesiano. Ele é, geralmente, o primeiro passo da análise explorativa de dados. Nele, podemos **começar** a explorar:

- **Sentido:** se há **associação** entre as variáveis (positiva ou negativa).
- **Intensidade:** se os pontos estão mais concentrados ou mais espalhados.

Gráfico de dispersão

O gráfico de dispersão representa cada par (x_i, y_i) por um ponto no plano cartesiano. Ele é, geralmente, o primeiro passo da análise explorativa de dados. Nele, podemos **começar** a explorar:

- **Sentido:** se há **associação** entre as variáveis (positiva ou negativa).
- **Intensidade:** se os pontos estão mais concentrados ou mais espalhados.
- **Forma:** se o padrão parece ser aproximadamente linear ou não.

Gráfico de dispersão

O gráfico de dispersão representa cada par (x_i, y_i) por um ponto no plano cartesiano. Ele é, geralmente, o primeiro passo da análise explorativa de dados. Nele, podemos **começar** a explorar:

- **Sentido:** se há **associação** entre as variáveis (positiva ou negativa).
- **Intensidade:** se os pontos estão mais concentrados ou mais espalhados.
- **Forma:** se o padrão parece ser aproximadamente linear ou não.
- **Pontos atípicos:** observações discrepantes.

Leitura visual essencial

Antes de calcular qualquer medida, observe se o padrão faz sentido substantivo e estatístico.

Como interpretar o padrão visual

Como interpretar o padrão visual

- **Associação positiva:** À medida que X cresce, os valores de Y tendem a crescer.

Como interpretar o padrão visual

- **Associação positiva:** À medida que X cresce, os valores de Y tendem a crescer.
- **Associação negativa:** À medida que X cresce, os valores de Y tendem a diminuir.

Como interpretar o padrão visual


- **Associação positiva:** À medida que X cresce, os valores de Y tendem a crescer.
- **Associação negativa:** À medida que X cresce, os valores de Y tendem a diminuir.
- **Associação fraca:** há grande dispersão dos pontos e o padrão (linear) é pouco nítido.

Cuidado



Ausência de correlação forte não significa independência; apenas sugere falta de associação *linear* marcada.

Correlação linear positiva




Correlação linear positiva






Correlação linear positiva



Correlação linear positiva



Correlação linear positiva




Da esquerda para a direita:



- $r = 1$: alinhamento perfeito crescente
- $r = 0,9$: forte associação linear positiva
- $r = 0,1$: associação linear positiva muito fraca

Correlação linear negativa




Correlação linear negativa






Correlação linear negativa



Correlação linear negativa



Correlação linear negativa




Da esquerda para a direita:

- $r = -1$: alinhamento perfeito decrescente
- $r = -0,9$: forte associação linear negativa
- $r = -0,1$: associação linear negativa muito fraca

Exercício: adivinhem as correlações

Acessem [Guessing Correlations](#)) e verifiquem se conseguem adivinhar corretamente, por favor.



O que os gráficos mostram

As simulações deixam clara a diferença entre **sinal** e **magnitude** da correlação.

- O **sinal** indica o sentido da associação: positivo ou negativo.
- O **módulo** $|r|$ indica a força da associação linear.
- Valores próximos de 1 ou -1 produzem nuvens de pontos mais alinhadas.
- Valores próximos de 0 produzem nuvens mais difusas.

Ideia importante

A correlação linear mede o quão bem uma **reta** descreve o padrão da nuvem de pontos.

Covariância

A covariância amostral pode ser escrita como

$$\text{Cov}(X, Y) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}).$$

Interpretação:

- positiva quando desvios de X e Y tendem a ter o mesmo sinal.
- negativa quando desvios de X e Y tendem a ter sinais opostos.
- próxima de zero quando não há co-variação linear marcada.

Limitação

A covariância depende das unidades de medida; por isso, sua magnitude isolada não é facilmente comparável entre contextos distintos.

Correlação linear de Pearson

A correlação padroniza a covariância:

$$r = \frac{\text{Cov}(X, Y)}{s_X s_Y}.$$

Propriedades centrais:

- $-1 \leq r \leq 1$
- $r > 0$: associação linear positiva
- $r < 0$: associação linear negativa
- $r = \pm 1$: alinhamento linear perfeito
- $r \approx 0$: associação linear fraca ou ausente

$$\text{Independência} \implies \text{Cov}(X, Y) = 0$$

$$\begin{aligned}\text{Independência} &\implies \text{Cov}(X, Y) = 0 \\ \text{Cov}(X, Y) = 0 &\not\Rightarrow \text{Independência}\end{aligned}$$

Cuidados de interpretação

Limites da correlação

A correlação é útil, mas não resolve toda a análise.

Ela pode ser enganosa quando:

- a relação é **não linear**
- existem **outliers** que distorcem a nuvem de pontos
- os dados misturam **subgrupos** muito diferentes
- se tenta concluir **causalidade** apenas a partir de associação

Limites da correlação

A correlação é útil, mas não resolve toda a análise.

Ela pode ser enganosa quando:

- a relação é **não linear**
- existem **outliers** que distorcem a nuvem de pontos
- os dados misturam **subgrupos** muito diferentes
- se tenta concluir **causalidade** apenas a partir de associação

Mensagem central

Correlação não implica causalidade.

Exercício

Com base nos dados abaixo, calcule a correlação entre Escolaridade e Salário

Indivíduo	Escolaridade (X)	Salário (Y)
1	12	3,2
2	8	2,0
3	18	5,0
4	14	3,8
5	10	2,5
6	20	5,5
7	12	3,0
8	16	4,5

Bussab, Wilton de Oliveira, and Pedro Alberto Morettin. 2010. *Estatística Básica*. 6th ed. São Paulo: Saraiva.

Sicsú, Abraham Laredo. 2010. *Credit Scoring: Desenvolvimento, Implantação e Acompanhamento*. 1st ed. São Paulo: Editora Blucher.