

Introdução à Estatística

Teorema de Bayes


João Ricardo Costa Filho

Leia os **livros**, não fique só com os slides!!!!

O Problema de Monty Hall


Monty Hall Problem

O apresentador de um programa de televisão oferece a oportunidade de ganhar um carro. Para isso, basta acertar atrás de qual das três portas ele está.



Monty Hall Problem

O apresentador de um programa de televisão oferece a oportunidade de ganhar um carro. Para isso, basta acertar atrás de qual das três portas ele está.



Após você escolher uma das portas, o apresentador abre uma das outras duas, revelando um bode, e oferece a escolha: **trocar de porta ou manter a escolha**. O que fazer?

Revisão: probabilidade condicional

Probabilidade condicional

A probabilidade de A dado que B ocorreu é:

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}, \quad P(B) > 0.$$

Probabilidade condicional

A probabilidade de A dado que B ocorreu é:

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}, \quad P(B) > 0.$$

Regra da multiplicação

$$P(A \cap B) = P(A \mid B) P(B) = P(B \mid A) P(A)$$

Partição do espaço amostral

Os eventos $A_1, A_2, \dots, A_n$ formam uma **partição** de Ω se:

1. São mutuamente exclusivos: $A_i \cap A_j = \emptyset$ para $i \neq j$.
2. São exaustivos: $A_1 \cup A_2 \cup \dots \cup A_n = \Omega$.

Partição do espaço amostral

Os eventos $A_1, A_2, \dots, A_n$ formam uma **partição** de Ω se:

1. São mutuamente exclusivos: $A_i \cap A_j = \emptyset$ para $i \neq j$.
2. São exaustivos: $A_1 \cup A_2 \cup \dots \cup A_n = \Omega$.



Teorema da probabilidade total

Seja $\{A_1, \dots, A_n\}$ uma partição de Ω e B qualquer evento. Então:

$$P(B) = \sum_{i=1}^n P(B \mid A_i) P(A_i).$$

Teorema da probabilidade total

Seja $\{A_1, \dots, A_n\}$ uma partição de Ω e B qualquer evento. Então:

$$P(B) = \sum_{i=1}^n P(B \mid A_i) P(A_i).$$


Intuição: B só pode ocorrer “dentro” de algum A_i . Basta somar as contribuições de cada pedaço.

Teorema da probabilidade total

Seja $\{A_1, \dots, A_n\}$ uma partição de Ω e B qualquer evento. Então:

$$P(B) = \sum_{i=1}^n P(B \mid A_i) P(A_i).$$

Intuição: B só pode ocorrer “dentro” de algum A_i . Basta somar as contribuições de cada pedaço.



Teorema de Bayes

Teorema de Bayes

Pelos axiomas da probabilidade e pela regra da multiplicação:

$$\begin{aligned} P(B) &= P(B \cap A_1) + P(B \cap A_2) + \cdots + P(B \cap A_n) \\ &= P(B \mid A_1)P(A_1) + \cdots + P(B \mid A_n)P(A_n) \\ &= \sum_{i=1}^n P(B \mid A_i) P(A_i). \end{aligned}$$

Teorema de Bayes

Sejam $A_1, A_2, \dots, A_n$ mutuamente exclusivos e exaustivos em Ω :

Teorema de Bayes

$$P(A_i | B) = \frac{P(B | A_i) P(A_i)}{\sum_{j=1}^n P(B | A_j) P(A_j)}$$

Teorema de Bayes

Sejam $A_1, A_2, \dots, A_n$ mutuamente exclusivos e exaustivos em Ω :

Teorema de Bayes

$$P(A_i | B) = \frac{P(B | A_i) P(A_i)}{\sum_{j=1}^n P(B | A_j) P(A_j)}$$

- $P(A_i)$: **probabilidade a priori** — o que sabíamos antes de observar B .
- $P(A_i | B)$: **probabilidade a posteriori** — o que aprendemos após observar B .
- $P(B | A_i)$: **verossimilhança** — quão compatível é B com a hipótese A_i .

A lógica do Teorema de Bayes

Como pensar

Observamos uma **evidência** B . O Teorema de Bayes nos diz como **atualizar** nossas crenças sobre qual hipótese A_i é mais provável, levando em conta essa evidência.

A lógica do Teorema de Bayes

Como pensar

Observamos uma **evidência** B . O Teorema de Bayes nos diz como **atualizar** nossas crenças sobre qual hipótese A_i é mais provável, levando em conta essa evidência.

Antes de observar B : $P(A_i)$ $\xrightarrow{\text{observamos } B}$ **Depois**: $P(A_i | B)$

A lógica do Teorema de Bayes

Como pensar

Observamos uma **evidência** B . O Teorema de Bayes nos diz como **atualizar** nossas crenças sobre qual hipótese A_i é mais provável, levando em conta essa evidência.


Antes de observar B : $P(A_i)$ $\xrightarrow{\text{observamos } B}$ **Depois**: $P(A_i | B)$

O “ganho de informação” depende de quão improvável seria observar B se A_i não fosse verdadeiro.

O Problema de Monty Hall


Monty Hall Problem

O apresentador de um programa de televisão oferece a oportunidade de ganhar um carro. Para isso, basta acertar atrás de qual das três portas ele está.



Monty Hall Problem

O apresentador de um programa de televisão oferece a oportunidade de ganhar um carro. Para isso, basta acertar atrás de qual das três portas ele está.



Após você escolher uma das portas, o apresentador abre uma das outras duas, revelando um bode, e oferece a escolha: **trocar de porta ou manter a escolha**. O que fazer?

Monty Hall: definindo os eventos

Sem perda de generalidade, suponha que você escolheu a **porta 1** e o apresentador abriu a **porta 3** (com bode).

Monty Hall: definindo os eventos

Sem perda de generalidade, suponha que você escolheu a **porta 1** e o apresentador abriu a **porta 3** (com bode).

Defina:

- C_i : o carro está atrás da porta i , $i = 1, 2, 3$.
- A_3 : o apresentador abre a porta 3.

Monty Hall: definindo os eventos

Sem perda de generalidade, suponha que você escolheu a **porta 1** e o apresentador abriu a **porta 3** (com bode).

Defina:

- C_i : o carro está atrás da porta i , $i = 1, 2, 3$.
- A_3 : o apresentador abre a porta 3.

Probabilidades a priori (antes de qualquer informação):

$$P(C_1) = P(C_2) = P(C_3) = \frac{1}{3}.$$

Monty Hall: as verossimilhanças

O apresentador **sabe** onde está o carro e **nunca** abre a porta escolhida nem a com o carro.

Monty Hall: as verossimilhanças

O apresentador **sabe** onde está o carro e **nunca** abre a porta escolhida nem a com o carro.

- $P(A_3 \mid C_1) = \frac{1}{2}$: carro na porta 1, abre 2 ou 3 com igual probabilidade.

Monty Hall: as verossimilhanças

O apresentador **sabe** onde está o carro e **nunca** abre a porta escolhida nem a com o carro.

- $P(A_3 | C_1) = \frac{1}{2}$: carro na porta 1, abre 2 ou 3 com igual probabilidade.
- $P(A_3 | C_2) = 1$: carro na porta 2, só pode abrir a porta 3.

Monty Hall: as verossimilhanças

O apresentador **sabe** onde está o carro e **nunca** abre a porta escolhida nem a com o carro.

- $P(A_3 | C_1) = \frac{1}{2}$: carro na porta 1, abre 2 ou 3 com igual probabilidade.
- $P(A_3 | C_2) = 1$: carro na porta 2, só pode abrir a porta 3.
- $P(A_3 | C_3) = 0$: carro na porta 3, não pode abri-la.

Monty Hall: aplicando Bayes

Probabilidade total de A_3 :

$$P(A_3) = \frac{1}{2} \cdot \frac{1}{3} + 1 \cdot \frac{1}{3} + 0 \cdot \frac{1}{3} = \frac{1}{6} + \frac{1}{3} = \frac{1}{2}.$$

Monty Hall: aplicando Bayes

Probabilidade total de A_3 :

$$P(A_3) = \frac{1}{2} \cdot \frac{1}{3} + 1 \cdot \frac{1}{3} + 0 \cdot \frac{1}{3} = \frac{1}{6} + \frac{1}{3} = \frac{1}{2}.$$

Probabilidades a posteriori pelo Teorema de Bayes:

$$P(C_1 | A_3) = \frac{\frac{1}{2} \cdot \frac{1}{3}}{\frac{1}{2}} = \frac{1}{3} \quad \text{(manter)}$$

Monty Hall: aplicando Bayes

Probabilidade total de A_3 :

$$P(A_3) = \frac{1}{2} \cdot \frac{1}{3} + 1 \cdot \frac{1}{3} + 0 \cdot \frac{1}{3} = \frac{1}{6} + \frac{1}{3} = \frac{1}{2}.$$

Probabilidades a posteriori pelo Teorema de Bayes:

$$P(C_1 | A_3) = \frac{\frac{1}{2} \cdot \frac{1}{3}}{\frac{1}{2}} = \frac{1}{3} \quad \textbf{(manter)}$$

$$P(C_2 | A_3) = \frac{1 \cdot \frac{1}{3}}{\frac{1}{2}} = \frac{2}{3} \quad \textbf{(trocar)}$$

Monty Hall: conclusão

Resultado

Após o apresentador revelar um bode na porta 3, a probabilidade de ganhar é $\frac{1}{3}$ se mantiver e $\frac{2}{3}$ se trocar. **Sempre compensa trocar!**

Monty Hall: conclusão

Resultado

Após o apresentador revelar um bode na porta 3, a probabilidade de ganhar é $\frac{1}{3}$ se mantiver e $\frac{2}{3}$ se trocar. **Sempre compensa trocar!**

Por que a intuição falha? A maioria das pessoas pensa que, com duas portas restantes, cada uma tem 50%. Isso ignoraria que o apresentador *não escolheu aleatoriamente* — ele tem informação e isso concentra probabilidade na porta não escolhida.

Monty Hall: conclusão

Resultado

Após o apresentador revelar um bode na porta 3, a probabilidade de ganhar é $1/3$ se mantiver e $2/3$ se trocar. **Sempre compensa trocar!**

Por que a intuição falha? A maioria das pessoas pensa que, com duas portas restantes, cada uma tem 50%. Isso ignoraria que o apresentador *não escolheu aleatoriamente* — ele tem informação e isso concentra probabilidade na porta não escolhida.

Moral: quando um agente informado age, sua ação carrega informação. O Teorema de Bayes captura exatamente isso.

Exemplos e exercícios

Exemplo 1: teste diagnóstico

Uma doença afeta 1% da população. Um teste detecta a doença em 95% dos doentes (*sensibilidade*) e classifica incorretamente 3% dos saudáveis como doentes (*especificidade* = 97%).

Exemplo 1: teste diagnóstico

Uma doença afeta 1% da população. Um teste detecta a doença em 95% dos doentes (*sensibilidade*) e classifica incorretamente 3% dos saudáveis como doentes (*especificidade* = 97%).

Uma pessoa testou **positivo**. Qual a probabilidade de ela estar doente?

Exemplo 1: teste diagnóstico

Uma doença afeta 1% da população. Um teste detecta a doença em 95% dos doentes (*sensibilidade*) e classifica incorretamente 3% dos saudáveis como doentes (*especificidade* = 97%).

Uma pessoa testou **positivo**. Qual a probabilidade de ela estar doente?

Defina: D = doente, D^c = saudável, T^+ = teste positivo.

- $P(D) = 0,01$; $P(D^c) = 0,99$.
- $P(T^+ | D) = 0,95$ (sensibilidade).
- $P(T^+ | D^c) = 0,03$ (falso positivo).

Exemplo 1: resolução

Probabilidade total de teste positivo:

$$P(T^+) = 0,95 \times 0,01 + 0,03 \times 0,99 = 0,0095 + 0,0297 = 0,0392.$$

Exemplo 1: resolução

Probabilidade total de teste positivo:

$$P(T^+) = 0,95 \times 0,01 + 0,03 \times 0,99 = 0,0095 + 0,0297 = 0,0392.$$

Pelo Teorema de Bayes:

$$P(D \mid T^+) = \frac{0,95 \times 0,01}{0,0392} = \frac{0,0095}{0,0392} \approx \mathbf{0,2423}.$$

Exemplo 1: resolução

Probabilidade total de teste positivo:

$$P(T^+) = 0,95 \times 0,01 + 0,03 \times 0,99 = 0,0095 + 0,0297 = 0,0392.$$

Pelo Teorema de Bayes:

$$P(D | T^+) = \frac{0,95 \times 0,01}{0,0392} = \frac{0,0095}{0,0392} \approx \mathbf{0,2423}.$$

Interpretação

Mesmo com teste positivo, a probabilidade de estar doente é de apenas **24%**. A prevalência baixa (1%) "dilui" o poder do teste.

Exemplo 1: tabela de frequências

É útil pensar em 10.000 pessoas:

	T^+	T^-	Total
Doente	95	5	100
Saudável	297	9603	9900
Total	392	9608	10000

Exemplo 1: tabela de frequências

É útil pensar em 10.000 pessoas:

	T^+	T^-	Total
Doente	95	5	100
Saudável	297	9603	9900
Total	392	9608	10000

$$P(D \mid T^+) = \frac{95}{392} \approx 0,2423.$$

A tabela mostra visualmente por que o resultado surpreende: os 297 falsos positivos superam em muito os 95 verdadeiros positivos.

Exemplo 2: controle de qualidade

Uma fábrica tem três máquinas. A máquina~1 produz 50% das peças, a máquina~2 produz 30% e a máquina~3 produz 20%. As taxas de defeito são: 2%, 3% e 5%, respectivamente.

Exemplo 2: controle de qualidade

Uma fábrica tem três máquinas. A máquina~1 produz 50% das peças, a máquina~2 produz 30% e a máquina~3 produz 20%. As taxas de defeito são: 2%, 3% e 5%, respectivamente.

Uma peça é retirada aleatoriamente e está **defeituosa**. Qual a probabilidade de ter sido produzida pela máquina~3?

Exemplo 2: controle de qualidade

Uma fábrica tem três máquinas. A máquina~1 produz 50% das peças, a máquina~2 produz 30% e a máquina~3 produz 20%. As taxas de defeito são: 2%, 3% e 5%, respectivamente.

Uma peça é retirada aleatoriamente e está **defeituosa**. Qual a probabilidade de ter sido produzida pela máquina~3?

Defina M_i = peça produzida pela máquina i e D = peça defeituosa.

Exemplo 2: resolução

Probabilidade total de defeito:

$$P(D) = 0,02 \times 0,50 + 0,03 \times 0,30 + 0,05 \times 0,20 = 0,010 + 0,009 + 0,010 = 0,029$$

Exemplo 2: resolução

Probabilidade total de defeito:

$$P(D) = 0,02 \times 0,50 + 0,03 \times 0,30 + 0,05 \times 0,20 = 0,010 + 0,009 + 0,010 = 0,029$$

Pelo Teorema de Bayes:

$$P(M_3 | D) = \frac{0,05 \times 0,20}{0,029} = \frac{0,010}{0,029} \approx \mathbf{0,345}.$$

Exemplo 2: resolução

Probabilidade total de defeito:

$$P(D) = 0,02 \times 0,50 + 0,03 \times 0,30 + 0,05 \times 0,20 = 0,010 + 0,009 + 0,010 = 0,029$$

Pelo Teorema de Bayes:

$$P(M_3 | D) = \frac{0,05 \times 0,20}{0,029} = \frac{0,010}{0,029} \approx \mathbf{0,345}.$$

Interpretação

A máquina 3 produz apenas 20% das peças, mas responde por **34,5%** das peças defeituosas — reflexo de sua maior taxa de defeito.

Exemplo 2: tabela resumo

Máquina	$P(M_i)$	$P(D \mid M_i)$	$P(D \cap M_i)$	$P(M_i \mid D)$
1	0,50	0,02	0,0100	0,345
2	0,30	0,03	0,0090	0,310
3	0,20	0,05	0,0100	0,345
Total	1,00	—	0,0290	1,000

Exemplo 2: tabela resumo

Máquina	$P(M_i)$	$P(D \mid M_i)$	$P(D \cap M_i)$	$P(M_i \mid D)$
1	0,50	0,02	0,0100	0,345
2	0,30	0,03	0,0090	0,310
3	0,20	0,05	0,0100	0,345
Total	1,00	—	0,0290	1,000

A tabela organiza os cálculos do Teorema de Bayes de forma sistemática: cada linha contribui para o denominador (probabilidade total) e o numerador de cada $P(M_i \mid D)$.

Exercício 1

Um banco classifica clientes em dois grupos: **alto risco** (A) e **baixo risco** (B).

- 25% dos clientes são de alto risco.
- Entre os de alto risco, 18% entram em inadimplência em 12 meses.
- Entre os de baixo risco, 4% entram em inadimplência.

Um cliente escolhido ao acaso entrou em inadimplência. Qual a probabilidade de pertencer ao grupo de alto risco?

Exercício 1: resolução

Defina I = inadimplência, A = alto risco, B = baixo risco.

- $P(A) = 0,25$; $P(B) = 0,75$.
- $P(I \mid A) = 0,18$; $P(I \mid B) = 0,04$.

Exercício 1: resolução

Defina I = inadimplência, A = alto risco, B = baixo risco.

- $P(A) = 0,25$; $P(B) = 0,75$.
- $P(I | A) = 0,18$; $P(I | B) = 0,04$.

$$P(I) = 0,18 \times 0,25 + 0,04 \times 0,75 = 0,045 + 0,030 = 0,075.$$

Exercício 1: resolução

Defina I = inadimplência, A = alto risco, B = baixo risco.

- $P(A) = 0,25$; $P(B) = 0,75$.
- $P(I | A) = 0,18$; $P(I | B) = 0,04$.

$$P(I) = 0,18 \times 0,25 + 0,04 \times 0,75 = 0,045 + 0,030 = 0,075.$$

$$P(A | I) = \frac{0,18 \times 0,25}{0,075} = \frac{0,045}{0,075} = \mathbf{0,60}.$$

Exercício 1: resolução

Defina I = inadimplência, A = alto risco, B = baixo risco.

- $P(A) = 0,25$; $P(B) = 0,75$.
- $P(I | A) = 0,18$; $P(I | B) = 0,04$.

$$P(I) = 0,18 \times 0,25 + 0,04 \times 0,75 = 0,045 + 0,030 = 0,075.$$

$$P(A | I) = \frac{0,18 \times 0,25}{0,075} = \frac{0,045}{0,075} = \mathbf{0,60}.$$

Resultado

Dado que o cliente é inadimplente, há **60%** de chance de ser alto risco — embora apenas 25% da carteira seja de alto risco.

Exercício 2

Uma fintech monitora transações com sistema de detecção de fraude:

- 1% das transações são fraudulentas.
- O sistema sinaliza 92% das transações fraudulentas.
- O sistema sinaliza erroneamente 6% das transações legítimas.

Uma transação foi sinalizada. Qual a probabilidade de ser realmente fraudulenta?

Exercício 2: resolução

Defina F = fraude, S = sinalizada.

- $P(F) = 0,01$; $P(F^c) = 0,99$.
- $P(S \mid F) = 0,92$; $P(S \mid F^c) = 0,06$.

Exercício 2: resolução

Defina F = fraude, S = sinalizada.

- $P(F) = 0,01$; $P(F^c) = 0,99$.
- $P(S | F) = 0,92$; $P(S | F^c) = 0,06$.

$$P(S) = 0,92 \times 0,01 + 0,06 \times 0,99 = 0,0092 + 0,0594 = 0,0686.$$

Exercício 2: resolução

Defina F = fraude, S = sinalizada.

- $P(F) = 0,01$; $P(F^c) = 0,99$.
- $P(S | F) = 0,92$; $P(S | F^c) = 0,06$.

$$P(S) = 0,92 \times 0,01 + 0,06 \times 0,99 = 0,0092 + 0,0594 = 0,0686.$$

$$P(F | S) = \frac{0,92 \times 0,01}{0,0686} = \frac{0,0092}{0,0686} \approx \mathbf{0,134}.$$

Exercício 2: resolução

Defina F = fraude, S = sinalizada.

- $P(F) = 0,01$; $P(F^c) = 0,99$.
- $P(S | F) = 0,92$; $P(S | F^c) = 0,06$.

$$P(S) = 0,92 \times 0,01 + 0,06 \times 0,99 = 0,0092 + 0,0594 = 0,0686.$$

$$P(F | S) = \frac{0,92 \times 0,01}{0,0686} = \frac{0,0092}{0,0686} \approx \mathbf{0,134}.$$

Resultado

Apenas **13,4%** das transações sinalizadas são fraudes de fato. O alto volume de legítimas gera muitos falsos positivos — problema clássico quando a prevalência é baixa.

Exercício 3

Considere uma economia em que:

- a probabilidade de recessão no próximo semestre é de 20%;
- quando há recessão, um indicador antecedente emite sinal vermelho em 75% dos casos;
- quando não há recessão, o indicador emite sinal vermelho em 15% dos casos.

O indicador emitiu sinal vermelho. Qual a probabilidade de ocorrer recessão?

Exercício 3: resolução

Defina R = recessão, V = sinal vermelho.

$$P(V) = 0,75 \times 0,20 + 0,15 \times 0,80 = 0,15 + 0,12 = 0,27.$$

Exercício 3: resolução

Defina R = recessão, V = sinal vermelho.

$$P(V) = 0,75 \times 0,20 + 0,15 \times 0,80 = 0,15 + 0,12 = 0,27.$$

$$P(R | V) = \frac{0,75 \times 0,20}{0,27} = \frac{0,15}{0,27} \approx \mathbf{0,556}.$$

Exercício 3: resolução

Defina R = recessão, V = sinal vermelho.

$$P(V) = 0,75 \times 0,20 + 0,15 \times 0,80 = 0,15 + 0,12 = 0,27.$$

$$P(R | V) = \frac{0,75 \times 0,20}{0,27} = \frac{0,15}{0,27} \approx \mathbf{0,556}.$$


Resultado

O sinal vermelho eleva a probabilidade de recessão de 20% (a priori) para **55,6%** (a posteriori). O indicador é informativo, mas não determinístico.

Aplicações e interpretações


Bayes e atualização de crenças

O Teorema de Bayes é a formalização matemática de como **aprender com a evidência**:



Bayes e atualização de crenças

O Teorema de Bayes é a formalização matemática de como **aprender com a evidência**:



- Cada nova observação atualiza a distribuição de crenças.
- A posteriori de hoje é a priori de amanhã.
- Essa lógica é a base da **estatística bayesiana**.

O efeito da prevalência

O exemplo do teste diagnóstico ilustra um ponto crucial: a **probabilidade a priori importa muito**.

O efeito da prevalência

O exemplo do teste diagnóstico ilustra um ponto crucial: a **probabilidade a priori importa muito**.

Prevalência	$P(T^+)$	$P(D T^+)$
1%	3,92%	24,2%
5%	7,60%	62,5%
10%	12,20%	77,9%
30%	47,60%	93,2%

{Sensibilidade = 95%, especificidade = 97% em todos os casos.}

O efeito da prevalência

O exemplo do teste diagnóstico ilustra um ponto crucial: a **probabilidade a priori importa muito**.

Prevalência	$P(T^+)$	$P(D \mid T^+)$
1%	3,92%	24,2%
5%	7,60%	62,5%
10%	12,20%	77,9%
30%	47,60%	93,2%

{Sensibilidade = 95%, especificidade = 97% em todos os casos.}

Lição

Um bom teste aplicado a uma população de baixa prevalência ainda produz muitos falsos positivos. Não é falha do teste — é matemática.

Independência revisitada

Dois eventos A e B são **independentes** se $P(A \mid B) = P(A)$.

Independência revisitada

Dois eventos A e B são **independentes** se $P(A \mid B) = P(A)$.

No contexto do Teorema de Bayes: se A e B são independentes, observar B não altera a probabilidade de A :

$$P(A \mid B) = \frac{P(B \mid A) P(A)}{P(B)} = P(A) \iff P(B \mid A) = P(B).$$

Independência revisitada

Dois eventos A e B são **independentes** se $P(A | B) = P(A)$.

No contexto do Teorema de Bayes: se A e B são independentes, observar B não altera a probabilidade de A :

$$P(A | B) = \frac{P(B | A) P(A)}{P(B)} = P(A) \iff P(B | A) = P(B).$$

Bayes e independência

Independência é o caso em que a evidência não atualiza as crenças. Na prática, a maioria dos eventos relevantes *não* é independente — e é exatamente aí que Bayes é útil.

\end{enumerate}

Bussab, Wilton de Oliveira, and Pedro Alberto Morettin. 2010. *Estatística Básica*. 6th ed. São Paulo: Saraiva.

Fry, Hannah. 2015. *The Mathematics of Love: Patterns, Proofs, and the Search for the Ultimate Equation*. Simon; Schuster.

Rozanov, Yurii A. 2013. *Probability Theory: A Concise Course*. Courier Corporation.

Sicsú, Abraham Laredo. 2010. *Credit Scoring: Desenvolvimento, Implantação e Acompanhamento*. 1st ed. São Paulo: Editora Blucher.

Silver, Nate. 2012. *The Signal and the Noise: Why so Many Predictions Fail—but Some Don't*. New York: Penguin Press.